

FIT5196-s2-2026-A1-Marking-Rubrics.pdf

FIT5196-s2-2026-A1-Specificaton.pdf

按照步骤告诉我应该干什么，以 hd 的标准

3

思考了 8s

可以。按照你上传的 **Specification + Marking Rubric**，这个作业想冲 **HD**，重点不是“代码能跑出来就行”，而是要做到：

代码正确 + 数据结构正确 + 每一步有证据 + validation 完整 + EDA 分析有逻辑 + 所有东西可复现。

而且这个作业不是普通的数据分析作业，实际上前半部分的数据清洗和验证占分非常高。总分 15 分，其中 **数据处理/整合/Regex/Validation 就有 10.5 分**，EDA 和 ML 问题 4.5 分，所以不能只把精力放在画图上。

你现在可以完全按照下面的顺序做。我建议**不要乱跳步骤**。

一、你现在第一步先不要写 EDA

先把老师给你的 **GroupNNN_A1.zip** 找出来。

里面应该至少有：

- A1_manifest.json
- README.md
- public_data_dictionary.csv
- raw_input/GroupNNN_commerce.json
- raw_input/GroupNNN_operations.xml

另外老师应该还给了模板：

- A1_source_to_target_mapping_template.csv
- A1_solution_template.ipynb
- A1_EDA_template.ipynb
- A1_public_text_test_cases.csv
- A1_AI_use_declaration_template.docx

这些才是我们后面真正干活需要的文件。

你现在应该做什么

把你的：

GroupNNN_A1.zip

上传给我。

如果你也有 templates 文件夹，最好一起上传。

因为你的 JSON/XML 结构是**每个 group 不同的**，Specification 明确说明 source path 并不是统一的，而是需要根据你自己 group 的数据检查。

二、拿到数据以后，第一阶段：检查文件，不要马上清洗

这是 Task 1。

你首先要建立一个：

Source Profiling

分别读取：

```
import json
```

```
import xml.etree.ElementTree as ET
```

JSON 必须用 JSON parser。

XML 必须用 XML parser。

绝对不要用 regex 解析 JSON/XML 结构。

这是 HD 的明确要求：JSON 和 XML 都必须使用合适的 structured parser，并且要展示 objects、nesting、repeated elements、grain、keys、formats 和 assumptions。

第 1.1 步：检查 JSON 结构

你需要回答这些问题：

JSON 有哪些顶层 objects?

比如可能类似：

customers

products

orders

reviews

但你不能猜，要从自己的文件里读。

需要打印：

data.keys()

然后查看：

type(data["xxx"])

len(data["xxx"])

data["xxx"][0]

目标是搞清楚：

一条 record 到底代表什么？

三、第 1.2 步：检查 XML 结构

同样不能直接 flatten。

先看：

tree = ET.parse(...)

root = tree.getroot()

print(root.tag)

for child in root:

print(child.tag)

然后确认：

- repeated elements 是什么
- 每个 element 下面有哪些字段
- 哪些 element 嵌套

- 哪些字段可能作为 ID

四、第 1.3 步：确定每一个数据集合的 grain

这是这个作业非常容易丢分的地方。

Grain = 一行究竟代表什么。

最终六个表要求非常明确：

Table	Grain	Primary key
orders	one canonical order	order_id
order_items	one order item	order_item_id
customers	one customer	customer_id
deliveries	one completed order delivery	delivery_id
products	one product	product_id
product_reviews	one canonical product review	review_id

所以你后面所有处理必须围绕这六个 grain 来。

五、第 1.4 步：检查 PK 和 FK

必须先检查 candidate keys。

例如：

```
df["order_id"].nunique()
```

```
len(df)
```

判断：

```
row count == unique key count?
```

还要检查 foreign key。

最终必须满足：

orders.customer_id

→ customers.customer_id

order_items.order_id

→ orders.order_id

order_items.product_id

→ products.product_id

deliveries.order_id

→ orders.order_id

product_reviews.order_id

→ orders.order_id

product_reviews.order_item_id

→ order_items.order_item_id

product_reviews.product_id

→ products.product_id

product_reviews.customer_id

→ customers.customer_id

而且这些 PK/FK 全部要求非空。

六、第 1.5 步：检查不同 source 的格式差异

这一部分必须在 notebook 里留下证据。

分别检查：

日期

例如：

2026-01-01

01/01/2026

2026/01/01

最终必须统一成：

YYYY-MM-DD

Timestamp

统一：

YYYY-MM-DD HH:MM:SS

Boolean

统一：

True

False

金额

例如：

\$1,299.95

AUD 1299.95

需要先去掉 currency symbol 和 thousands separator。

Percentage

统一成 data dictionary 指定的 numeric percentage points。

Specification 明确要求这些标准化。

七、非常重要：做 Source-to-Target Mapping

这是 A2。

很多学生会忽视它， 但 HD 要求：

95%-100%的 mapping rows 完整、准确、可追踪。

你需要填写老师给的：

A1_source_to_target_mapping_template.csv

每个 target field 都要写清楚：

source_format

json_source_path

xml_source_path

transformation_or_derivation

overlap_or_conflict_rule

notebook_evidence

例如：

target	source_format	JSON path	XML path	transformation	overlap rule	evidence
order_id	both	orders[].id	orders/order/id	uppercase/strip	compare normalized value	MAP-ORD-01

不要写：

"comes from order_id"

这种没意义。

要写：

JSON: transactions[].order.id

XML: /operations/orders/order/orderCode

这种才叫 traceable。

HD 要求 mapping 的六个字段全部能追踪到 notebook。

八、第二阶段：正式生成六张表

这是整个作业最重要的技术部分。

必须生成：

GroupNNN_orders_standardised.csv

GroupNNN_order_items_standardised.csv

GroupNNN_customers_standardised.csv

GroupNNN_deliveries_standardised.csv

GroupNNN_products_standardised.csv

GroupNNN_product_reviews_standardised.csv

HD 目标

六张表：

一个都不能缺。

而且：

- filenames 正确
- field names 正确
- field order 正确
- grain 正确
- primary keys complete
- primary keys unique

而且 key coverage 必须达到：

95%-100%。

Field-value accuracy 也要达到：

95%-100%。

九、不要把所有东西 flatten 成一个大表

这是大忌。

例如一个 order 有：

1 order

↓

3 order_items

↓

2 reviews

如果你直接 merge：

`orders.merge(items).merge(reviews)`

可能变成：

1 order × 3 items × 2 reviews

= 6 rows

然后你的 revenue 就被重复计算。

所以必须保持 one-to-many 关系。

Rubric 明确说：

one-to-many relationships 必须保持 relational form。

十、第三阶段：处理 duplicates 和 cross-source overlap

这是 C 部分，1.5 分。

需要处理两类：

① within-source duplicate

JSON 自己内部重复。

或者：

XML 自己内部重复。

② cross-source overlap

例如 JSON:

ORDER001

XML 也有:

ORDER001

最终只能保留一个 canonical record。

但不能简单:

drop_duplicates()

也不能:

JSON 优先

或者:

XML 优先

正确做法是:

normalize

↓

compare stable business key

↓

compare fields

↓

if same → merge/retain once

↓

if conflict → log conflict

Specification 明确说:

正常情况下标准化以后重复数据应当一致, 因此**不需要任意设 JSON 优先或 XML 优先**。如果同一个 key 出现不同 non-missing values, 应该记录 conflict, 而不是偷偷覆盖。

十一、第四阶段：金额计算必须完全按照老师顺序

这个千万不要自己发挥。

正确顺序：

Step 1

line_revenue =
quantity * unit_price
round 2 decimals。

Step 2

order_price =
sum(line_revenue)
round 2 decimals。

Step 3

GST:
tax_amount =
order_price / 11
因为价格是 GST-inclusive。

Step 4

应用：
coupon_discount

Step 5

加：
delivery_charges

Step 6

最终：
order_total
round 2 decimals。

特别注意：

tax_amount 不能再加到 **order_total** 里面。

这是 private/reference comparison 很可能直接测的。

十二、第五阶段：Regex 和 Unicode

这部分占：

2.5 / 15

其实很多。

首先要建立单独文件：

GroupNNN_text_functions.py

必须存在 6 个函数：

clean_narrative_text()

extract_order_reference()

extract_product_sku()

extract_promo_code()

build_latin_analysis()

contains_non_latin_script()

函数名字、参数个数、return contract 都是固定的。

十三、文本处理必须严格按照这个顺序

不能随便换顺序。

① structured parser 取 value

↓

② 先 extract:

- Order reference
- SKU
- Promo code

↓

③ HTML entity decode

例如:

&

→ &

再做:

`unicodedata.normalize("NFC", ...)`

↓

④ 删除 HTML/XML tags

↓

⑤ 删除:

[SYSTEM]

[CATALOGUE]

[VERIFIED_PURCHASE]

[SOURCE: ...]

[RATING: n/5]

#verified-buyer

@store_support

URL

emoji

↓

⑥ 删除完整 reference wrapper

↓

⑦ 删除：

PROMO: CODE

↓

⑧ whitespace normalize

↓

⑨ lower-case

↓

⑩ 如果没有 human-readable text：

返回：

"NaN"

注意：

这里是字符串：

"NaN"

不是：

np.nan

规则本身在 Specification 里按顺序给得非常明确。

十四、Regex 必须通过 near-match edge cases

三个 reference：

Order

必须：

HORD + exactly 6 digits

或者：

CORD + exactly 6 digits

例如：

HORD123456

正确。

但：

HORD1234567

不能误匹配成：

HORD123456

SKU

SKU-

+

one or more ASCII letters/digits

Promotion

B1SAVE-

到

B5SAVE-

+

exactly two digits

而且返回必须 uppercase。

near-match 必须 reject。

十五、Unicode 这里是 HD 和普通答案的区别

一定记住：

review_body_clean

必须保留：

中文

日本語

한국어

é

ñ

ü

不能：

```
text.encode("ascii", errors="ignore")
```

这会直接把 multilingual 内容删掉。

review_body_latin_analysis

这是另外一个字段。

它才删除 non-Latin letters。

但必须保留 Latin diacritics，例如：

é

à

ö

ñ

contains_non_latin_script

检测：

是否存在 non-Latin **letters**

不是：

是否存在 non-ASCII 字符。

例如：

café

包含非 ASCII é,

但它仍然是 Latin script。

所以：

```
contains_non_latin_script("café")
```


应该：

False

Specification 专门强调了这个区别。

十六、第六阶段：自己写测试

不能只运行老师 public tests。

要测：

正常 case

HORD123456

unmatched

hello world

missing

None

multilingual

商品很好 café

malformed

HORD1234567

boundary

ABCHORD123456XYZ

HD 要求 public cases + focused additional tests, 并且 private test pass rate 目标要：

90%-100%。

十七、第七阶段：Validation Register

这个作业绝对不能只写：

```
print(df.info())
```

老师要的是：

Executable validation checks。

每个 check 给一个稳定 ID。

例如：

VAL-SCHEMA-01

VAL-PK-01

VAL-PK-02

VAL-FK-01

VAL-ARITH-01

VAL-TIME-01

VAL-TEXT-01

VAL-UNICODE-01

每一个都要有：

ID

Check

Observed result

PASS/FAIL

Evidence

Interpretation / resolution

Specification 明确要求 stable validation ID 和 observed result、PASS/FAIL、resolution。

十八、Validation 至少检查这些

HD 不要漏：

Schema

- 六张表存在
- columns 正确
- column order 正确

Data type

- numeric
- date
- timestamp
- boolean
- string NaN

Primary key

notnull

unique

Foreign key

比如：

```
set(order_items.order_id).issubset(set(orders.order_id))
```

Range

例如：

quantity > 0

rating valid

price >= 0

Source coverage

source rows

→ processed

→ overlap removed

→ canonical rows

Duplicate/overlap

说明：

within JSON

within XML

cross-source

Arithmetic

验证：

order_price

tax

discount

delivery

total

Temporal

例如：

order_time <= dispatch_time

dispatch_time <= delivered_time

适用的情况下。

Regex

order / SKU / promo。

Multilingual

clean text 没有错误删除非 Latin 内容。

Rubric 的 HD validation 要求覆盖 schema、types、missing、PK/FK、row flow、overlap、arithmetic、temporal order、text refs、multilingual 和 range。

十九、真正冲 HD：不要害怕 FAIL validation

这是很关键的一点。

如果源数据真的有问题：

VAL-TIME-04 = FAIL

这并不意味着你一定扣分。

如果你：

检测出来

↓

展示证据

↓

解释为什么

↓

给合理处理方案

仍然可以拿 validation 和 interpretation 分。

老师甚至明确说：真实的 validation failure，如果正确识别并提出合理 treatment，仍可以得分；为了让 assertion 通过而伪造数据反而不行。

二十、第八阶段：Restart & Run All

做完 solution notebook 后：

点击：

Kernel

→ Restart Kernel

→ Run All

必须确保：

从空 kernel

↓

不用手动点任何东西

↓

生成全部 6 CSV

↓

运行全部 validation

另外路径必须：

GROUP_ID = "NNN"

INPUT_DIR = ...

OUTPUT_DIR = ...

不要：

C:\Users\你的名字\Desktop\...

两个 notebook 都必须能 fresh kernel Run All，并使用 configurable/relative paths。

这一步很重要，Rubric 有整整：

1 分 E2。

二十一、第九阶段：现在才开始 EDA

EDA 是 3.5 分，权重非常高。

要求：

做 6-8 张 assessed visualisations

建议直接：

做 8 张。

但是记住：

只有前 8 张明确标为 assessed 的图会评分。

你画 12 张没有用，第 9 张开始不参与补救前面的弱图。

二十二、8 张图必须覆盖六个 category

我建议你这样设计。

Figure 1 — Univariate

Order value distribution

例如：

订单金额分布

table:

orders

Chart:

histogram / ECDF

Figure 2 — Composition

Product/category revenue composition

可能使用：

orders + order_items + products

但一定先把金额算在正确 grain。

Figure 3 — Bivariate

例如：

Coupon discount vs order value

或者：

Customer segment vs order value

Figure 4 — Multivariate

例如：

Order value × discount × customer segment

可以：

boxplot + segmentation

或者：

scatter + facet

Figure 5 — Temporal

例如：

order revenue by week/day/time

必须确认：

observation unit = order

不要拿 order_items 重复订单。

Figure 6 — Review behaviour

例如：

rating vs review length

或者：

language/script vs rating/helpfulness

Figure 7 — Delivery performance

例如：

delivery delay vs order value

需要：

deliveries + orders

Figure 8 — Strong relational analysis

例如：

delivery delay

vs

review rating

连接：

deliveries

orders

product_reviews

但这张一定要先聚合，否则 one-to-many 会爆炸。

Specification 要求 6-8 幅图覆盖：

1. univariate
2. bivariate
3. multivariate
4. temporal
5. review/text

6. delivery/operational

并且整体至少使用 4/6 张表，还需要至少 2 次正确 relational analysis。

二十三、每一张图前面必须写 6 样东西

这部分非常非常重要。

每一个 Figure 写：

1. Analytical question

例如：

Does delivery delay vary with order value?

2. Observation unit

例如：

one completed delivery

3. Denominator

例如：

n = 1,246 completed deliveries

4. Tables

例如：

orders

deliveries

5. Join key

order_id

6. Limitation

例如：

The relationship is observational and may reflect product mix or geographic differences.

老师把这些明确写成 visualisation 要求。

二十四、不要只写“Figure shows X is higher”

这是 C/D 水平。

HD finding 需要：

量化。

例如不要写：

Late deliveries received lower ratings.

要写类似：

Among 436 completed deliveries with associated reviews, orders delivered after the promised date had a median rating of 3.8 compared with 4.2 for on-time deliveries, a difference of 0.4 points. However, the association may partly reflect differences in product category or order complexity; therefore, the result should motivate segmented analysis rather than a causal conclusion.

这种结构就对了。

二十五、第十阶段：正好写 10 条 Findings

注意：

不是“至少 10”。

而是：

exactly 10

每条 finding 用固定模板：

Finding X

Evidence

Figure 4

Grain

order level

Magnitude

median / mean / % / n

Business meaning

为什么重要。

Alternative explanation

可能还有什么解释。

Implication

建议下一步怎么办。

HD 要求前 10 条中的 **9-10 条** 都要有强证据，并正确陈述 grain、magnitude/denominator、context、uncertainty/alternative explanation 和 proportionate implication。

二十六、不要写因果关系

千万避免：

Discount causes customers to spend more.

你的数据基本上是 observational。

应该：

Higher discounts were associated with higher order values.

然后：

This should not be interpreted causally because...

HD rubric 明确要求：

Association is not presented as causation.

二十七、第十一阶段：正好 5 个 ML Questions

注意：

exactly 5

而且不需要训练模型。

Specification 直接说：

Do not train or compare models in A1.

所以别浪费时间跑 Random Forest、XGBoost。

二十八、5 个 ML 问题最好覆盖 3 种 task

例如：

ML1 — Classification

预测：

Will an order be delivered late?

ML2 — Regression

预测：

delivery duration

ML3 — Classification

预测：

will a review be low-rating?

ML4 — Forecasting

预测：

weekly order demand / revenue

ML5 — Anomaly Detection

识别：

unusual order behaviour

这样远远满足“至少两种 problem types”。

二十九、每个 ML 问题必须回答 7 项

不要只写：

Can we predict delivery delay?

那拿不到 HD。

必须包括：

① **Business decision**

比如：

which orders should receive operational intervention?

② **Prediction unit**

one order

③ **Target**

late_delivery = 0/1

④ **Predictors**

而且必须是：

decision-time available predictors

例如订单刚创建时：

order value

product mix

delivery region

item count

customer history

但不能用：

actual_delivery_time

review_rating

因为那时候还没发生。

⑤ **Validation split**

例如时间型数据：

train earlier period

test later period

比 random split 更合理。

⑥ Metric

分类：

ROC-AUC

F1

PR-AUC

回归：

MAE

RMSE

⑦ Risk

例如：

target leakage

temporal leakage

fairness

deployment drift

HD 要求 5 个问题全部 feasible、grounded in EDA，并覆盖这些 design/risk elements。

三十、第十二阶段：写最终 PDF

文件：

GroupNNN_EDA.pdf

正文：

最多 10 页

Cover、contents、references 不计入这 10 页。

建议结构就按照老师给的：

1. Problem Context and Data Scope

约 0.5 页

2. Data Preparation Assurance

约 1 页

写:

3-5 个关键 transformation decisions

例如:

- JSON/XML structural parsing
- duplicate reconciliation
- monetary standardisation
- multilingual cleaning
- relational grain preservation

再写:

4-6 个关键 validation results

引用:

MAP-...

VAL-...

3. Assessed Visualisations

大约 4-5 页。

Figure 1-8。

4. Ten Findings

约 2 页。

5. Five ML Questions

约 1.5-2 页。

6. Limitations

约 0.5 页。

7. Conclusion

约 0.25-0.5 页。

这个结构就是 Specification 推荐的结构。

三十一、最终 Run All 检查

最后一次必须做：

Solution notebook

Restart

↓

Run All

↓

全部成功

再检查：

EDA notebook

Restart

↓

Run All

↓

全部成功

并且 EDA notebook 应该：

从六张最终 CSV 读取数据。

不要重新偷偷跑另一套 cleaning pipeline。

三十二、最终 submission 结构一定要长这样

GroupNNN_A1_submission.zip

```
|
|
|—— GroupNNN_solution.ipynb
|—— GroupNNN_solution.py
|—— GroupNNN_EDA.ipynb
|—— GroupNNN_text_functions.py
|—— GroupNNN_source_to_target_mapping.csv
|—— GroupNNN_AI_declaration.pdf
|—— requirements.txt
|
|—— AI_records/
|   |—— GroupNNN_AI_index.pdf
|   |—— complete_chat_exports...
|
|—— outputs/
|   |—— GroupNNN_orders_standardised.csv
|   |—— GroupNNN_order_items_standardised.csv
|   |—— GroupNNN_customers_standardised.csv
|   |—— GroupNNN_deliveries_standardised.csv
|   |—— GroupNNN_products_standardised.csv
|   |—— GroupNNN_product_reviews_standardised.csv
```

另外单独上传：

GroupNNN_EDA.pdf

不要把 EDA.pdf 放 ZIP 里面。

不要提交老师给你的 raw JSON/XML。

三十三、还有一个你现在特别需要注意的问题：AI Declaration

因为你现在已经使用 ChatGPT 帮助这个 assignment，所以按这份 Specification：

你们需要提交：

GroupNNN_AI_declaration.pdf

而且如果用了 conversational AI，还要求：

AI_records/

里面放：

GroupNNN_AI_index.pdf

complete_chat_exports

并写明：

- AI 用于什么
- 用在 submission 哪里
- 如何 independently verified

而且 Specification 明确说不能只截取有利片段，需要完整导出 assignment 相关 conversation。FIT5196-s2-2026-A1-Specificaton.pdfPDF

这个一定不要最后一天才做。

你冲 HD 最需要盯住的 7 个数字

我给你浓缩一下：

项目	HD 目标
Mapping completeness	95–100%
Key coverage	95–100%
Field-value accuracy	95–100%
Private text tests	90–100%

项目	HD 目标
Assessed figures	6-8, 建议 8
Findings	正好 10
ML questions	正好 5

这些不是我自己定的，是 Rubric 中的直接评分门槛。FIT5196-s2-2026-A1-Marking-Rubrics.pdfPDF

所以你现在具体只做一件事情

先不要自己往后做 EDA。

把你的：

GroupNNN_A1.zip

上传给我。

最好同时把老师的：

templates 文件夹

也一起给我。

我拿到以后，我们可以严格按照 HD 标准一项一项往下做：

① 检查你的 JSON/XML → ② 确定 grain 和 keys → ③ 做 mapping → ④ 写 transformation → ⑤ 生成六张 CSV → ⑥ Regex 六个函数 → ⑦ public+edge tests → ⑧ validation register → ⑨ HD 级 EDA 设计 → ⑩ 10 Findings → ⑪ 5 ML Questions → ⑫ 最终检查。

这样做会比你先零散写代码再回来补作业结构安全很多。