

Group030_A1.zip

请你告诉我清洗数据的时候需要分成哪些表

思考了 34s


需要，而且你们这个 Group030_A1 不是自己随意决定拆表数量。我刚刚检查了你上传的压缩包，README.md 明确要求最终创建 6 张 cleaned tables，并且 public_data_dictionary.csv 已经把六张表的字段、数据类型和 nullable 都规定好了。

所以你们清洗完成后，最终应该分成下面 6 张表：

表名	粒度 Grain	主键 PK	主要外键 FK	作用
orders	一行一个订单	order_id	customer_id → customers.customer_id	订单主体
order_items	一行一个订单商品	order_item_id	order_id → orders, product_id → products	订单里的商品明细
customers	一行一个客户	customer_id	—	客户信息
deliveries	一行一个已完成订单的配送	delivery_id	order_id → orders.order_id	配送信息
products	一行一个商品	product_id	—	商品主数据
product_reviews	一行一条商品评价	review_id	order_id、order_item_id、product_id、customer_id	评论及文本清洗结果

也就是说，你们最终的逻辑结构应该理解成：

customers



1. orders

这一张是**订单主表**，不能把每件商品放成一行，否则会造成订单字段大量重复。

你们规定的字段一共 **23 个**：

order_id

source_system_record_id

customer_id

order_timestamp

sales_channel

payment_method

currency

nearest_warehouse

order_status

order_price
delivery_charges
coupon_code
coupon_discount
tax_amount
order_total
season
expedited_delivery
customer_lat
customer_long
device_type
referral_source
customer_note_clean
promo_code

例如原始 XML 里面：

```
<Order>  
  <Header>...</Header>  
  <Shopping_Cart>...</Shopping_Cart>  
  <Delivery>...</Delivery>  
</Order>
```

其中 <Header> 基本就是要整理进 orders。

需要注意：

- order_id 必须唯一
- customer_id 必须能在 customers 找到
- 金额要转成 numeric
- % 要处理
- 日期时间标准化

- Y/N 等要转 boolean
- customer_note 要做文本清洗
- 从 narrative text 中提取 promo_code

2. order_items

这是订单商品明细表。

一个订单可以买 1、2、3、4 件甚至更多商品，因此一定不能和 orders 强行做成同一张表。

字段：

order_item_id

order_id

product_id

quantity

unit_price

line_revenue

比如：

HORD000587

这个订单可能对应：

HITM0001851

HITM0001852

HITM0001853

HITM0001854

因此结构应该是：

order_id	order_item_id	product_id
HORD000587	HITM0001851	PRD0520
HORD000587	HITM0001852	PRD0839
HORD000587	HITM0001853	PRD0756

HORD000587 HITM0001854 PRD0316

这里一个非常重要的 HD validation 是：

$\text{line_revenue} \approx \text{quantity} \times \text{unit_price}$

以及：

$\text{SUM}(\text{order_items.line_revenue})$

$\approx \text{orders.order_price}$

允许根据 specification 使用对应数值容差。

3. customers

这是**客户维度表**。

字段共 20 个：

customer_id

signup_date

loyalty_tier

customer_segment

age_band

preferred_channel

home_suburb

prior_12m_orders

lifetime_value_before_period

marketing_consent

home_postcode

home_state

home_country

preferred_language

acquisition_source

account_status

preferred_device
email_domain
household_size_band
contact_frequency_preference

原则是：

同一个 customer 不应该因为买过很多次东西而出现很多行。

最终应该：

customer_id

CUS00001

CUS00002

CUS00003

...

每个 customer_id 只能一行。

你们后面 validation 要重点查：

customers["customer_id"].is_unique

以及：

orders.customer_id

$\subseteq$

customers.customer_id

否则就是 orphan foreign key。

4. deliveries

配送数据应该独立成表，而不是全部塞进 orders。

字段共 20 个：

delivery_id

order_id

dispatch_date

promised_date
delivered_date
carrier
service_level
delivery_status
delay_days
on_time_in_full
fulfilment_hours
delivery_cost
delay_reason
promised_days
tracking_event_count
delivery_window
shipping_distance_km
signature_required
estimated_carbon_kg
delivery_note_clean

这一张表尤其适合做 **temporal validation**。

例如应该检查：

order_timestamp
 $\leq$ dispatch_date
 $\leq$ delivered_date

还应该验证：

delay_days

和 promised / delivered date 是否一致。

例如：

Promised_Date = 04/08/2018

Delivered_Date = 08/08/2018

Delay_Days = 4

这就是合理的。

你们 rubric 里面提到的：

temporal relationships

基本上这一部分就必须在 deliveries 和 orders 之间检查。

5. products

这是商品主表。

字段共 **21** 个：

product_id

product_name

category

brand

unit_price

unit_cost

launch_year

warranty_months

weight_kg

product_sku

subcategory

model_family

colour

supplier_id

supplier_country

launch_date

tax_category

package_type

recyclable_packaging

active_flag

product_description_clean

其中：

product_id

应该是 PK。

然后：

order_items.product_id

product_reviews.product_id

都应该引用这里。

也就是说 validation：

order_items.product_id

$\subseteq$

products.product_id

以及：

product_reviews.product_id

$\subseteq$

products.product_id

6. product_reviews

这是你们这次比较容易丢分、但也最容易体现 HD 水平的一张表。

字段多达 **21** 个：

review_id

order_id

order_item_id

product_id

customer_id
review_timestamp
language_code
rating
review_title
review_body_clean
review_body_latin_analysis
verified_purchase
helpful_votes
review_length_chars
review_word_count
contains_non_latin_script
extracted_order_reference
extracted_product_sku
delivery_experience
value_experience
writing_style

这里特别要注意两个不同的文本字段：

review_body_clean

和

review_body_latin_analysis

不能做成同一个东西。

README 已经明确规定：

review_body_clean

要：

- 保留 multilingual text
- 保留 lowercase multilingual review

- 删除 HTML
- 删除 emoji
- 删除 URL
- 删除 [SYSTEM]
- 删除 [CATALOGUE]
- 删除 [VERIFIED_PURCHASE]
- 合并重复 whitespace

而：

review_body_latin_analysis

要另外创建，只保留 Latin-script letters，包括：

é

ö

ü

ñ

à

等欧洲变音字符。

同时还需要 regex 提取：

订单：

[HC]ORD\d{6}

例如：

HORD000587

CORD123456

商品 SKU：

SKU-[A-Za-z0-9]+

优惠码：

B[1-5]SAVE-\d{2}

所以你们不要额外乱拆很多最终表

最终 submission 的 cleaned data, 核心就是:

1. orders
2. order_items
3. customers
4. deliveries
5. products
6. product_reviews

这个是你们数据包自己规定的, 不是我推测的。

你可以在程序内部暂时建立:

json_orders_raw

xml_orders_raw

json_customers_raw

xml_customers_raw

overlap_check

validation_results


这些中间 **dataframe** 没有问题。


但是最终 cleaned output 应该落到上述 六张标准表。

你们整个清洗逻辑最好这样组织


如果你现在是为了拿 HD, 我建议整个 pipeline 按这个顺序:

RAW JSON





RAW XML



|



schema normalisation

|

type normalisation

|

missing-value handling

|

text / regex cleaning

|

source-overlap reconciliation

|



FINAL 6 TABLES

|



VALIDATION

而 validation 最好至少覆盖：

Schema

Types

Missing

PK uniqueness

FK integrity

Source / row flow

Overlap reconciliation

Arithmetic

Temporal relationships

Text / regex

Domain / range checks

因此你之前问的“validation 应该按照 schema、types、missing、PK/FK、source/row flow、overlap...”这个方向是正确的。

最关键的一点是：****不要把 JSON 清洗成一套最终表、XML 清洗成另一套最终表。JSON/XML 是 source，最终需要 reconciliation 后进入同一套 6 张 canonical tables。这会直接影响你们 overlap、source coverage 和 row-flow validation 能不能写到 HD 水平。**