

drive-download-20260904T120449Z-1-001.zip

Group030_A1.zip

參照 public task 給我生成建議給我的 task

可以。根据你们 **Group030_A1** 的 README、数据字典，以及老师给的 A1_public_text_test_cases.csv，我建议你们自己设计的 **student-designed tasks/tests** 不要重复 public cases，而是专门补 public tests 没覆盖好的“边界情况”。这会更符合 HD 的思路，因为老师模板明确要求你们展示 **matched**、**unmatched**、**missing**、**multilingual**、**near-match** 等自设计测试。

你们的数据明确要求处理 6 个 text/regex 相关函数，所以我建议自己的 task 至少做下面 **12-15** 个。

建议 Task ID	Function	Input 示例	Expected output	主要测试目的
STU-01	clean_narrative_text	[SYSTEM] Delivery was FAST!!!	delivery was fast!!!	同时测试 marker + HTML + lowercase
STU-02	clean_narrative_text	Great product	great product	HTML entity + repeated whitespace
STU-03	clean_narrative_text	[UNKNOWN] Keep this text	[unknown] keep this text	不能误删未知 marker
STU-04	clean_narrative_text	Visit https://shop.example/item?id=123 for help	visit for help	URL 带 query string

建议 Task ID	Function	Input 示例	Expected output	主要测试 目的
STU -05	clean_narrative_text	😊😊 Excellent café ☕	excellent café	emoji 删除但 Latin diacritics 保留
STU -06	extract_order_reference	Order HORD000001 confirmed	HORD000001	最小边界、合法HORD
STU -07	extract_order_reference	Order CORD999999 confirmed	CORD999999	合法CORD
STU -08	extract_order_reference	XCORD123456Y	NaN	bounded regex, 拒绝嵌入匹配
STU -09	extract_order_reference	HORD1234567	NaN	多一位数字不能截取前缀
STU -10	extract_product_sku	sku-Z9A0B1	SKU-Z9A0B1	lower-case prefix + 字母数字 混合
STU -11	extract_product_sku	SKU-ABC_123	NaN	underscore 不属于允许字符

建议 Task ID	Function	Input 示例	Expected output	主要测试目的
STU-12	extract_promo_code	Use B1SAVE-00 today	B1SAVE-00	B1 + 数字边界
STU-13	extract_promo_code	Use B6SAVE-24 today	NaN	B 只能是 1-5
STU-14	contains_non_latin_script	café déjà vu	False	欧洲重音字符仍属于 Latin
STU-15	contains_non_latin_script	Great product 很好	True	Latin + Chinese 混合
STU-16	build_latin_analysis	Très bon! 商品 😊 10/10	très bon 10 10*	保留 Latin 字符, 去 non-Latin/emoji
STU-17	build_latin_analysis	非常好 😊	NaN	去除后无 Latin letter
STU-18	clean_narrative_text	None / missing value	NaN	missing handling

* STU-16 的具体标点/数字结果, 要与你最终实现规则完全一致。如果你们函数规定保留 /, expected output 就应该相应调整; 重点是 测试必须反映你们实际规则, 而不是为了 PASS 改答案。

我最推荐你们提交的组合

如果不想写太多，我建议至少选择这 12 个：

STU-02、03、04、05、06、07、08、10、11、13、14、17

原因是它们和 public task 的重复度最低，同时把 HD 比较看重的几个点都覆盖到了：

- **matched case**: 合法 HORD/CORD/SKU/promo
- **unmatched case**: 非法 B6SAVE、非法 SKU
- **near-match**: XCORD123456Y
- **missing**: 可以再额外放 STU-18
- **multilingual**: 中英文混合
- **Unicode**: café, Très
- **negative test**: 未知 [UNKNOWN] marker 不应该被误删
- **boundary regex**: 避免合法 regex 从非法长字符串中截出部分结果

尤其是 **STU-03** 很值得加。public task 已经有：

[NOTE] Keep bracketed customer wording

目的就是检查你们不要使用类似：

```
re.sub(r'\[.*?\]', '', text)
```

这种过于宽泛的 Regex。

你们真正应该只删 README 明确允许删除的：

[SYSTEM]

[CATALOGUE]

[VERIFIED_PURCHASE]

再加 public task 暗示的合法 parameterised marker，例如：

[RATING: 4/5]

而不是“看到方括号全部删”。

另外，你们 Group030 的 Regex 核心规则我建议按下面的边界思路设计：

Order reference:

```
(?<![A-Za-z0-9])[HC]ORD\d{6}(?![A-Za-z0-9])
```

Product SKU:

```
(?<![A-Za-z0-9])SKU-[A-Za-z0-9]+(?![A-Za-z0-9-])
```

Promo:

```
(?<![A-Za-z0-9])B[1-5]SAVE-\d{2}(?![A-Za-z0-9])
```

但 **SKU** 的最终边界要特别测试 **SKU-ABC123-extra**，因为 public case 已经明确要求这种情况返回 NaN，不能错误返回 SKU-ABC123。所以你们最好不要只依赖简单的 \b。

你们在 **notebook** 里可以这样组织

3.2 Public and student-designed tests 下分成两张结果表：

Public tests:

直接读取 A1_public_text_test_cases.csv，运行全部 18 个。

Student-designed tests:

你们自己建立类似：

```
student_tests = [  
    {  
        "case_id": "STU-01",  
        "function": "clean_narrative_text",  
        "input_value": "...",  
        "expected_output": "...",  
        "purpose": "..."  
    },  
    ...  
]
```

然后统一产生：

case_id

function

input_value

expected_output

actual_output

pass

purpose

最终最好显示：

Public tests: 18 / 18 PASS

Student-designed tests: 12 / 12 PASS

而不是仅用几个 assert，因为表格形式更适合放进 validation evidence，也更容易让 marker 看清楚你们覆盖了哪些边界条件。

如果你这里说的“task”是指 EDA 的 Figure 1-6 / 五个 ML task，而不是 student-designed regex test，我也可以直接根据 Group030 的 orders、customers、deliveries、products、reviews 六张表，给你生成一套完整的 HD 级 EDA task。